INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
DE SANTA CATARINA

CÂMPUS SÃO JOSÉ

WAGNER FLORES DOS SANTOS

ANÁLISE COMPARATIVA ENTRE ARQUITETURAS DE AGENTE ÚNICO E MULTIAGENTE BASEADAS EM LLM PARA CHATBOTS DE ATENDIMENTO

SÃO JOSÉ

2026

Wagner Flores dos Santos

Análise Comparativa entre Arquiteturas de Agente Único e Multiagente Baseadas em LLM para Chatbots de Atendimento

Pré-projeto apresentado à Unidade Curricular de Trabalho de Conclusão de Curso I do Curso de Engenharia de Telecomunicações do Instituto Federal de Educação, Ciência e Tecnologia de Santa Catarina – Câmpus São José.

Área de concentração: Telecomunicações.

Orientador: Prof. Arliones Stevert Hoeller Júnior, Dr.

São José

2026

RESUMO

Os modelos de linguagem de grande escala (LLMs) ampliaram as possibilidades de automação do atendimento ao cliente, permitindo interpretar solicitações, consultar informações e produzir respostas mais flexíveis do que as obtidas com fluxos baseados apenas em regras. Ainda não está claro, porém, em quais condições a distribuição das responsabilidades entre agentes especializados oferece vantagens suficientes para compensar o aumento da complexidade e do consumo de recursos em relação a uma arquitetura de agente único. Este trabalho tem como objetivo comparar experimentalmente as duas arquiteturas em um cenário controlado de atendimento textual de um provedor de Internet, considerando a correção e a relevância das respostas, a conclusão das tarefas, a precisão dos encaminhamentos, o tempo de resposta e o consumo de tokens. Para isso, serão implementados dois protótipos, submetidos ao mesmo conjunto balanceado de casos de teste e às mesmas condições de execução, com avaliação apoiada pelo DeepEval e por métricas registradas diretamente durante o experimento. Espera-se identificar em quais situações a especialização por agentes setoriais melhora o atendimento e quais efeitos essa organização produz sobre a latência, o uso de tokens e o custo operacional.

Palavras-chave: modelos de linguagem de grande escala; sistemas multiagentes; chatbots; atendimento ao cliente; agentes inteligentes.

ABSTRACT

Large language models (LLMs) have expanded the possibilities for automating customer service by enabling systems to interpret requests, retrieve information, and produce more flexible responses than those generated by rule-based workflows. However, it remains unclear under which conditions distributing responsibilities among specialized agents provides sufficient advantages to offset the increased complexity and resource consumption compared with a single-agent architecture. This study aims to experimentally compare both architectures in a controlled text-based customer service scenario for an Internet service provider, considering response correctness and relevance, task completion, routing accuracy, response time, and token consumption. To this end, two prototypes will be implemented and evaluated using the same set of conversational test cases under equivalent execution conditions, with assessments supported by DeepEval and metrics recorded directly during the experiment. The expected outcome is to identify the situations in which specialization through domain-specific agents improves customer service and the effects of this organization on latency, token usage, and operational cost.

Keywords: large language models; multi-agent systems; chatbots; customer service; intelligent agents.

LISTA DE QUADROS

Quadro 1 – Síntese dos trabalhos relacionados 16

LISTA DE ABREVIATURAS E SIGLAS

LLM modelo de linguagem de grande escala (*Large Language Model*).

SUMÁRIO

1 INTRODUÇÃO 7
1.1 PROBLEMA DE PESQUISA 8
1.2 JUSTIFICATIVA 8
1.3 OBJETIVOS 9
1.3.1 Objetivo geral 9
1.3.2 Objetivos específicos 9
1.4 DELIMITAÇÃO DO TRABALHO 10

2 REVISÃO BIBLIOGRÁFICA 11
2.1 FUNDAMENTAÇÃO TEÓRICA 11
2.1.1 Modelos de linguagem de grande escala 11
2.1.2 Agentes baseados em modelos de linguagem 11
2.1.3 Arquiteturas de agente único e multiagente 12
2.1.4 Comunicação, orquestração e retenção de contexto 13
2.1.5 Avaliação de sistemas conversacionais 14
2.2 TRABALHOS RELACIONADOS 15
2.3 SÍNTESE DA REVISÃO E LACUNA DE PESQUISA 16

3 METODOLOGIA 18
3.1 NATUREZA DO TRABALHO 18
3.2 DELINEAMENTO EXPERIMENTAL 18
3.2.1 Variáveis do experimento 19
3.3 ETAPAS DO TRABALHO 19
3.4 MATERIAIS E FERRAMENTAS 19
3.5 CENÁRIOS CONVERSACIONAIS 20
3.6 PROCEDIMENTO EXPERIMENTAL 20
3.7 MÉTRICAS E CRITÉRIOS DE AVALIAÇÃO 20
3.8 PRIVACIDADE E PROTEÇÃO DOS DADOS 21
3.9 RISCOS E LIMITAÇÕES 21

Referências 22

1 INTRODUÇÃO

Os modelos de linguagem de grande escala (LLMs, *Large Language Model*) ampliaram as possibilidades de automação de atividades que envolvem compreensão e geração de linguagem natural. Quando integrados a bases de informações, ferramentas e mecanismos de decisão, esses modelos podem formar agentes capazes de interpretar solicitações, manter o contexto de uma conversa e executar tarefas com algum grau de autonomia. No atendimento ao cliente, essa abordagem permite desenvolver soluções mais flexíveis do que os chatbots baseados apenas em regras e fluxos predefinidos.

Trabalhos recentes apresentam aplicações de LLMs na classificação de chamados e na geração de respostas de suporte (MONCADA et al., 2025), bem como arquiteturas formadas por agentes coordenadores e especializados para atuar em diferentes componentes de sistemas de telecomunicações (LEE; TSENG; CHEN, 2025). Essas soluções podem ser organizadas em arquiteturas de agente único ou multiagente.

Na arquitetura de agente único, um mesmo componente recebe as mensagens, mantém o histórico da conversa, consulta as informações disponíveis, decide o procedimento e produz as respostas. Essa centralização reduz a necessidade de coordenação entre componentes. Em uma arquitetura multiagente, essas responsabilidades são distribuídas entre agentes com funções específicas, como triagem, atendimento comercial, primeiro atendimento, ouvidoria e suporte técnico. A divisão pode facilitar a especialização e reduzir o contexto recebido por cada agente, mas também introduz etapas adicionais de comunicação e novos pontos de falha (YAN et al., 2026).

A comunicação entre os agentes influencia a eficiência, a escalabilidade e a robustez do sistema. Uma decisão incorreta na triagem pode encaminhar a conversa para um agente que não possui as informações necessárias. Também podem ocorrer perdas de contexto, encaminhamentos desnecessários ou propagação de erros entre os componentes. Esses riscos tornam relevante avaliar não apenas a resposta final, mas também o caminho percorrido pelo atendimento (OWOTOGBE, 2025).

A literatura também apresenta estudos sobre o encaminhamento de conversas para atendimento humano e o reconhecimento de intenções em ambientes multiagentes (AMRI et al., 2026; YANG; XU; ZHANG, 2025). Os resultados apontam benefícios da especialização, mas também mostram que a vantagem da arquitetura multiagente não ocorre em todas as métricas e pode vir acompanhada de maior latência ou de transferências realizadas mais cedo. Além disso, os trabalhos adotam diferentes modelos, cenários e critérios de avaliação, o que dificulta uma comparação direta entre arquiteturas de agente único e multiagente.

Esses resultados indicam que a adoção de uma arquitetura multiagente não representa, necessariamente, uma melhoria em todas as situações. Ainda são necessárias comparações nas quais as arquiteturas utilizem o mesmo modelo, a mesma base de informações, parâmetros equivalentes e cenários de atendimento comparáveis. Também é necessário observar o comportamento ao longo da conversa, considerando a retenção do contexto, as decisões de encaminhamento e os recursos utilizados até a conclusão da tarefa.

1.1 PROBLEMA DE PESQUISA

A escolha entre uma arquitetura de agente único e uma arquitetura multiagente envolve um compromisso entre qualidade, complexidade e custo operacional. A especialização pode melhorar o tratamento de determinadas solicitações, mas exige coordenação entre agentes e pode aumentar o número de chamadas ao modelo, a latência e o consumo de tokens.

Além disso, uma avaliação baseada somente em perguntas isoladas não representa todo o funcionamento de um chatbot de atendimento. Em uma conversa real, as informações são fornecidas gradualmente, e uma resposta depende das mensagens anteriores. O sistema também pode precisar rever o encaminhamento quando o usuário apresenta uma nova informação ou muda o assunto durante o atendimento.

Diante desse contexto, este trabalho busca responder à seguinte pergunta:

> Quais diferenças de desempenho são observadas entre uma arquitetura de agente único e uma arquitetura multiagente, ambas baseadas em modelos de linguagem de grande escala e aplicadas a cenários conversacionais de atendimento, quanto à correção e à relevância das respostas, à retenção do contexto, à conclusão das tarefas, à precisão dos encaminhamentos, ao tempo de resposta e ao consumo de tokens?

1.2 JUSTIFICATIVA

A escolha da arquitetura influencia tanto a qualidade do atendimento quanto o custo de operação de sistemas baseados em LLMs. Uma solução centralizada pode ser suficiente para tarefas simples e utilizar menos chamadas ao modelo. Por outro lado, a distribuição das responsabilidades entre agentes especializados pode favorecer situações que exigem regras específicas ou mudanças de setor durante uma conversa, embora acrescente etapas de comunicação e novos pontos de falha (YAN et al., 2026).

No atendimento de provedores de Internet, uma mesma conversa pode envolver dúvidas gerais, solicitações comerciais, reclamações e problemas técnicos. Um encaminha-

mento incorreto pode levar o usuário para uma fila inadequada, prolongar o atendimento ou produzir uma resposta sem as informações necessárias. Estudos anteriores demonstram que a especialização pode melhorar determinadas métricas, mas essa vantagem não ocorre em todas as situações. Também foi observada uma tendência de o sistema multiagente realizar transferências para o atendimento humano mais cedo (AMRI et al., 2026).

A contribuição esperada deste trabalho é a implementação de dois protótipos equivalentes e a realização de uma comparação controlada entre as arquiteturas. A avaliação considerará tanto o resultado final quanto a trajetória da conversa, incluindo a retenção do contexto, os encaminhamentos realizados, a quantidade de turnos e os recursos consumidos. Os resultados poderão servir como referência para pesquisadores e desenvolvedores na escolha de uma arquitetura compatível com os requisitos de qualidade, desempenho e custo da aplicação.

1.3 OBJETIVOS

1.3.1 Objetivo geral

Comparar experimentalmente o desempenho de uma arquitetura de agente único e de uma arquitetura multiagente, ambas baseadas em modelos de linguagem de grande escala e aplicadas a cenários conversacionais de atendimento textual de um provedor de internet.

1.3.2 Objetivos específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- definir uma base comum de informações e regras de atendimento para as duas arquiteturas;
- implementar um protótipo de agente único e um protótipo multiagente composto por um agente de triagem e agentes especializados;
- elaborar e validar um conjunto de cenários conversacionais de teste para primeiro atendimento, comercial, ouvidoria e suporte técnico;
- avaliar a correção e a relevância das respostas, a retenção do contexto, a conclusão das tarefas e a precisão dos encaminhamentos;
- medir o tempo de resposta, o consumo de tokens, o número de chamadas ao modelo, a quantidade de turnos e as trocas de agente realizadas durante cada conversa;
- comparar os resultados para identificar as vantagens, limitações e custos de cada arquitetura.

1.4 DELIMITAÇÃO DO TRABALHO

O estudo será restrito ao atendimento textual e utilizará cenários sintéticos baseados em situações de um provedor de Internet. Os dados empregados serão fictícios ou anonimizados, sem interação com clientes reais.

As duas arquiteturas utilizarão o mesmo modelo de linguagem, os mesmos parâmetros de geração e a mesma base geral de informações. No agente único, todas as regras serão reunidas em um único contexto. No sistema multiagente, o conteúdo será distribuído conforme as responsabilidades de cada agente.

Não fazem parte do escopo o atendimento por voz, o processamento de conteúdo multimodal, o treinamento ou ajuste fino de modelos, a comparação entre diferentes LLMs e a implantação do sistema com clientes reais. Também não serão realizados testes de robustez com injeção deliberada de falhas nos agentes ou na comunicação.

2 REVISÃO BIBLIOGRÁFICA

Este capítulo apresenta os conceitos utilizados no desenvolvimento do trabalho e discute pesquisas relacionadas ao uso de modelos de linguagem em sistemas de atendimento. São abordados os agentes baseados em modelos de linguagem, as arquiteturas de agente único e multiagente, a comunicação entre agentes e os critérios empregados na avaliação de sistemas conversacionais.

2.1 FUNDAMENTAÇÃO TEÓRICA

2.1.1 Modelos de linguagem de grande escala

Os modelos de linguagem de grande escala são capazes de interpretar instruções e produzir textos a partir do contexto fornecido em sua entrada. Em sistemas de atendimento, esses modelos podem ser utilizados para identificar a intenção do usuário, consultar informações e elaborar respostas adequadas à solicitação recebida.

Diferentemente de um fluxo baseado somente em regras fixas, um sistema apoiado em LLMs pode tratar diferentes formas de expressar uma mesma intenção. Essa característica é útil em conversas nas quais o usuário não segue um roteiro predefinido ou fornece as informações de maneira incompleta.

O comportamento do modelo depende das instruções, das informações disponíveis e do histórico incluído no contexto. Uma resposta também pode variar entre execuções, mesmo quando a entrada é semelhante. Por esse motivo, a utilização de LLMs em processos de atendimento exige critérios que permitam verificar a correção das respostas e o cumprimento das regras definidas para o serviço.

Yang, Xu e Zhang observam que modelos de linguagem podem melhorar o reconhecimento de intenções em comparação com métodos baseados somente em regras ou classificação tradicional. Os autores também destacam o custo computacional e a latência associados ao seu uso (YANG; XU; ZHANG, 2025). Esses fatores são relevantes neste trabalho porque as arquiteturas comparadas podem realizar quantidades diferentes de chamadas ao modelo.

2.1.2 Agentes baseados em modelos de linguagem

Um agente baseado em modelo de linguagem combina o modelo com instruções que definem sua função, informações de contexto e mecanismos para executar ações. Em um chatbot de atendimento, essas ações podem incluir classificar uma solicitação, consultar uma base de informações, formular uma resposta ou encaminhar a conversa para outro

setor.

As instruções fornecidas ao agente delimitam sua atuação. Um agente de suporte técnico, por exemplo, pode receber regras sobre os testes permitidos, os dados que devem ser solicitados e as situações que exigem transferência para atendimento humano. O histórico da conversa permite utilizar informações fornecidas em mensagens anteriores e evitar que o usuário tenha que repeti-las.

Agentes baseados em modelos de linguagem também podem utilizar mecanismos de memória e recuperação de informações. Yan et al. destacam que técnicas de geração aumentada por recuperação podem fornecer ao modelo informações obtidas de fontes externas ou de memórias estruturadas. Nesse tipo de abordagem, os conteúdos relevantes são recuperados dinamicamente e inseridos no contexto utilizado para produzir a resposta (YAN et al., 2026). No presente trabalho, entretanto, não será implementado um mecanismo completo de recuperação, pois as informações serão fornecidas aos agentes por meio de bases previamente definidas e distribuídas conforme suas responsabilidades.

Moncada et al. utilizam agentes especializados para realizar a ingestão de dados, a classificação de chamados e a geração de respostas em uma aplicação de suporte ao cliente (MONCADA et al., 2025). O trabalho mostra que uma tarefa de atendimento pode ser dividida entre componentes com responsabilidades distintas. Essa divisão, entretanto, exige que as informações necessárias sejam transmitidas corretamente entre os agentes.

2.1.3 Arquiteturas de agente único e multiagente

Na arquitetura de agente único, um mesmo agente concentra as funções necessárias ao atendimento. Ele recebe as mensagens, interpreta a solicitação, mantém o histórico, consulta as informações disponíveis e produz a resposta. As regras dos diferentes setores ficam reunidas no contexto desse agente.

Essa organização reduz a necessidade de encaminhamentos internos. Por outro lado, o aumento da quantidade de regras e assuntos pode tornar o contexto mais extenso e dificultar a separação das responsabilidades. O agente precisa identificar quais instruções devem ser aplicadas em cada situação.

Na arquitetura multiagente, as responsabilidades são divididas entre agentes com funções específicas. Um agente pode realizar a triagem da conversa, enquanto outros tratam de assuntos comerciais, técnicos ou administrativos. Lee, Tseng e Chen apresentam uma organização semelhante para sistemas de suporte à operação de telecomunicações, composta por um agente principal e agentes especializados (LEE; TSENG; CHEN, 2025).

A especialização permite limitar as instruções e informações recebidas por cada agente. Em contrapartida, torna necessário definir como o sistema seleciona o próximo agente e quais partes do histórico serão transferidas. Assim, parte do desempenho da

arquitetura passa a depender do mecanismo de coordenação.

Amri et al. comparam arquiteturas de agente único e multiagente no encaminhamento de conversas para atendimento humano (AMRI et al., 2026). Os resultados apresentados pelos autores indicam diferenças entre as arquiteturas, mas não demonstram vantagem da abordagem multiagente em todos os critérios. Essa constatação reforça a necessidade de comparar as duas alternativas sob as mesmas condições.

Yan et al. classificam as arquiteturas de comunicação de sistemas multiagentes baseados em modelos de linguagem em estruturas planas, hierárquicas, por equipes, de sociedade e híbridas. Na arquitetura hierárquica, agentes de nível superior coordenam ou direcionam a execução de agentes responsáveis por tarefas específicas. Essa organização facilita a divisão de responsabilidades, mas pode introduzir pontos de concentração, aumento da latência e sobrecarga de comunicação (YAN et al., 2026). A arquitetura multiagente proposta neste trabalho aproxima-se desse modelo, pois utiliza um agente de triagem para direcionar as mensagens aos agentes especializados e realizar novo encaminhamento quando ocorre mudança de assunto.

2.1.4 Comunicação, orquestração e retenção de contexto

A orquestração corresponde ao controle do fluxo de execução entre os agentes. Em uma arquitetura multiagente de atendimento, esse mecanismo recebe a mensagem, identifica a função necessária e direciona a conversa para o agente responsável. Quando o assunto muda, uma nova decisão de encaminhamento pode ser necessária.

Yan et al. analisam os sistemas multiagentes a partir da comunicação estabelecida entre seus componentes (YAN et al., 2026). Segundo essa perspectiva, não basta avaliar separadamente a capacidade de cada agente, pois o resultado também depende das mensagens trocadas e das decisões tomadas durante a execução.

Em uma conversa com vários turnos, as informações costumam ser fornecidas aos poucos. O usuário pode informar inicialmente que está sem acesso à Internet e, somente depois, relatar o estado das luzes do equipamento. Se houver troca de agente entre essas mensagens, o novo agente precisa receber os dados já coletados.

Neste trabalho, a retenção de contexto será observada pela capacidade de utilizar corretamente informações apresentadas em mensagens anteriores. Também serão registrados os encaminhamentos realizados ao longo da conversa. Com isso, será possível distinguir um erro na resposta de um erro ocorrido anteriormente na triagem ou na transferência de informações.

A análise de Yan et al. diferencia aspectos de nível sistêmico e aspectos internos da comunicação. No nível sistêmico, são considerados a arquitetura, o objetivo da comunicação e os protocolos utilizados. No nível interno, são observados a sequência das

interações, a forma das mensagens, os participantes e o conteúdo transferido (YAN et al., 2026). Essa distinção é pertinente a este trabalho, pois a comparação envolve tanto a organização dos agentes quanto o caminho percorrido pelas mensagens e as informações preservadas durante os encaminhamentos.

Falhas em um componente podem afetar as etapas seguintes de um sistema multiagente. Owotogbe discute esse problema ao investigar a robustez de sistemas formados por agentes baseados em modelos de linguagem (OWOTOGBE, 2025). Embora a injeção deliberada de falhas não faça parte do escopo deste trabalho, a possibilidade de propagação de erros justifica o acompanhamento do fluxo percorrido por cada atendimento.

2.1.5 Avaliação de sistemas conversacionais

A avaliação de um sistema conversacional pode considerar tanto a resposta entregue ao usuário quanto o processo utilizado para produzi-la. Uma resposta pode estar correta, mas ter sido obtida após encaminhamentos desnecessários, repetição de perguntas ou uso excessivo de chamadas ao modelo.

A correção indica se a resposta está de acordo com as informações disponíveis. A relevância verifica se ela trata diretamente da solicitação apresentada. A retenção de contexto observa se os dados fornecidos anteriormente foram utilizados de forma adequada. Já a conclusão da tarefa verifica se o objetivo definido para o cenário foi alcançado.

Em uma arquitetura multiagente, também é necessário avaliar a precisão dos encaminhamentos. Essa medida permite verificar se cada mensagem foi direcionada ao agente responsável pelo assunto. As métricas de qualidade podem ser acompanhadas por medidas operacionais, como tempo de resposta, consumo de tokens, número de chamadas ao modelo e quantidade de trocas de agente.

Ferramentas de avaliação de aplicações baseadas em modelos de linguagem podem combinar verificações objetivas com métricas baseadas em um modelo avaliador. Neste trabalho, será utilizado o DeepEval para examinar aspectos semânticos das conversas, como relevância das respostas, retenção de informações e conclusão do atendimento. Resultados objetivos, como intenção identificada, rota entre agentes e encaminhamento final, serão verificados separadamente por regras determinísticas.

Esses critérios permitem comparar as arquiteturas para além da resposta final. No experimento proposto, os mesmos cenários, o mesmo modelo de linguagem e a mesma base de informações serão empregados nos dois protótipos. Os detalhes das métricas e do procedimento experimental serão apresentados no capítulo de metodologia.

2.2 TRABALHOS RELACIONADOS

Os trabalhos analisados abordam diferentes aspectos do uso de modelos de linguagem e sistemas multiagentes. Alguns apresentam aplicações voltadas ao atendimento, enquanto outros tratam do reconhecimento de intenções, da comunicação entre agentes e da robustez dessas arquiteturas.

Moncada et al. (2025) apresentam uma arquitetura multiagente para automação de chamados de suporte. A solução foi implementada com o *framework* CrewAI e distribui as tarefas entre agentes responsáveis pela entrada dos dados, classificação dos chamados e geração das respostas. Os autores relatam resultados de acurácia na classificação e de similaridade semântica entre as respostas produzidas e as respostas esperadas. O trabalho demonstra uma aplicação prática da especialização de agentes, mas não realiza uma comparação controlada com uma arquitetura de agente único nem acompanha conversas com múltiplos turnos.

No contexto das telecomunicações, Lee, Tseng e Chen (2025) propõem uma arquitetura para sistemas de suporte à operação. A organização é composta por um agente principal, responsável pela coordenação, e agentes específicos, encarregados de tarefas relacionadas a diferentes áreas do sistema. Os autores apontam benefícios relacionados à flexibilidade e à divisão de responsabilidades. Entretanto, o estudo concentra-se na descrição da arquitetura e não apresenta uma comparação experimental entre agente único e multiagente utilizando os mesmos cenários e parâmetros.

O reconhecimento de intenções é investigado por Yang, Xu e Zhang (2025). Os autores propõem uma abordagem em duas etapas: inicialmente, é realizada uma tentativa de classificação utilizando TF-IDF; quando essa etapa não é suficiente, um modelo de linguagem é empregado. A proposta procura equilibrar precisão, latência e custo computacional. O estudo é pertinente ao mecanismo de triagem, mas sua avaliação está concentrada na identificação da intenção, sem abranger a continuidade do atendimento depois do encaminhamento.

Amri et al. (2026) comparam arquiteturas de agente único e multiagente na decisão de encaminhar uma conversa para atendimento humano. Para realizar os testes, os autores utilizam uma base formada por diálogos de atendimento e comparam o desempenho das arquiteturas com diferentes modelos de linguagem. Os resultados indicam melhor desempenho do sistema multiagente em parte das medidas avaliadas. Entretanto, também mostram que a organização em múltiplos agentes pode alterar o momento em que ocorre a transferência. O estudo é próximo da proposta deste trabalho, mas está concentrado na decisão de transferência para humanos.

A comunicação em sistemas multiagentes baseados em modelos de linguagem é analisada por Yan et al. (2026). Os autores organizam as arquiteturas a partir dos partici-

pantes, dos tipos de mensagens, das estruturas de comunicação e das estratégias utilizadas para coordenar as tarefas. A revisão também discute problemas como aumento do custo de comunicação, propagação de erros e dificuldade de manter informações consistentes entre os agentes. Por se tratar de uma revisão, o trabalho não realiza uma comparação experimental própria, mas fornece a base conceitual para analisar a comunicação entre os componentes.

A robustez dos sistemas multiagentes é discutida por Owotogbe (2025), que propõe o uso de princípios de engenharia do caos para avaliar o comportamento do sistema diante de falhas. O trabalho considera que problemas em um agente ou na comunicação podem afetar o resultado produzido pelos demais componentes. Embora este TCC não inclua a injeção deliberada de falhas, essa discussão mostra a importância de registrar os encaminhamentos e observar em qual etapa ocorre um resultado incorreto.

O Quadro 1 resume as principais características dos trabalhos analisados e sua relação com a proposta desta pesquisa.

Quadro 1 – Síntese dos trabalhos relacionados

Trabalho	**Aplicação**	**Abordagem**	**Limitação em relação a este TCC**
Moncada et al. (MONCADA et al., 2025)	Chamados de suporte	Agentes para entrada dos dados, classificação e geração de respostas	Não compara as duas arquiteturas nem avalia conversas com múltiplos turnos
Lee, Tseng e Chen (LEE; TSENG; CHEN, 2025)	Operações de telecomunicações	Agente principal coordenando agentes especializados	Não apresenta comparação experimental controlada entre agente único e multiagente
Yang, Xu e Zhang (YANG; XU; ZHANG, 2025)	Reconhecimento de intenção	Classificação inicial com TF-IDF e uso de LLM como segunda etapa	Avalia a identificação da intenção, mas não a continuidade do atendimento
Amri et al. (AMRI et al., 2026)	Transferência para atendimento humano	Comparação entre agente único e multiagente	Concentra-se na decisão de transferência para atendimento humano
Yan et al. (YAN et al., 2026)	Comunicação entre agentes	Revisão de arquiteturas, mensagens e estratégias de comunicação	Não realiza comparação experimental própria
Owotogbe (OWOTOGBE, 2025)	Robustez de sistemas multiagentes	Aplicação de princípios de engenharia do caos	Possui procedimento e objetivo experimental diferentes

Fonte: Elaborada pelo autor.

2.3 SÍNTESE DA REVISÃO E LACUNA DE PESQUISA

Os trabalhos analisados mostram que a divisão de responsabilidades entre agentes pode ser aplicada à classificação de solicitações, ao encaminhamento de conversas e à execução de tarefas especializadas. Também indicam que a comunicação entre os compo-

nentes pode aumentar a complexidade do sistema e introduzir problemas relacionados à latência, ao consumo de recursos e à perda de informações.

Entre os estudos selecionados, o trabalho de Amri et al. (2026) é o que mais se aproxima da comparação proposta neste TCC. Entretanto, sua avaliação está direcionada ao encaminhamento para atendimento humano. Os demais estudos analisam aplicações ou aspectos específicos das arquiteturas, sem comparar agente único e multiagente durante conversas que possam envolver diferentes setores.

Permanece, portanto, a necessidade de uma comparação na qual as duas arquiteturas utilizem o mesmo modelo de linguagem, a mesma base de informações, parâmetros equivalentes e os mesmos cenários de atendimento. Além da resposta final, essa comparação deve observar a retenção das informações fornecidas ao longo da conversa, as decisões de encaminhamento e os recursos utilizados por cada arquitetura.

Com base nessa lacuna, este trabalho propõe implementar dois protótipos equivalentes e submetê-los a cenários conversacionais de atendimento de um provedor de Internet. O procedimento de implementação, os cenários e as métricas de avaliação são apresentados no capítulo seguinte.

3 METODOLOGIA

Este capítulo apresenta o método proposto para comparar uma arquitetura de agente único e uma arquitetura multiagente em atendimentos textuais de um provedor de Internet. A comparação será realizada em condições controladas, utilizando os mesmos cenários conversacionais, a mesma base de informações e o mesmo modelo de linguagem. Além da resposta final, serão observados o desenvolvimento da conversa, as decisões de encaminhamento e os recursos consumidos durante cada execução.

3.1 NATUREZA DO TRABALHO

O trabalho possui natureza aplicada e experimental. A etapa aplicada compreende o desenvolvimento de dois protótipos de atendimento baseados em modelos de linguagem de grande escala. A etapa experimental consiste na execução de um conjunto comum de cenários conversacionais e na comparação dos resultados obtidos pelas duas arquiteturas.

Não se pretende desenvolver um sistema comercial completo. Os protótipos serão utilizados como instrumentos de experimentação, com as funções necessárias para receber mensagens, manter o histórico da conversa, produzir respostas e registrar informações sobre cada execução.

3.2 DELINEAMENTO EXPERIMENTAL

O experimento terá como fator de comparação a arquitetura utilizada no atendimento. Serão avaliadas uma arquitetura de agente único e uma arquitetura multiagente. As duas soluções receberão as mesmas entradas e serão submetidas às mesmas condições de execução.

Na arquitetura de agente único, um único componente será responsável por interpretar as mensagens, manter o contexto, consultar as regras disponíveis e produzir as respostas. Na arquitetura multiagente, uma etapa de triagem definirá o primeiro destino da conversa. O agente especializado manterá o atendimento enquanto o assunto permanecer em sua área e solicitará nova decisão de encaminhamento quando identificar uma mudança de assunto.

Para reduzir interferências externas, serão mantidos iguais entre os protótipos o modelo de linguagem, os parâmetros de geração, a base geral de informações e as regras de atendimento. Os prompts serão diferentes apenas no que for necessário para representar as responsabilidades de cada arquitetura. A versão do modelo, os parâmetros utilizados e as versões das bibliotecas serão registrados juntamente com os resultados.

3.2.1 Variáveis do experimento

A variável independente será a arquitetura de atendimento, com dois níveis: agente único e sistema multiagente. As variáveis dependentes serão as métricas de qualidade, encaminhamento e consumo obtidas em cada conversa.

Serão controlados o modelo de linguagem, os parâmetros de geração, a base de informações, os cenários, a ordem das mensagens e o ambiente de execução. Caso sejam realizadas repetições, a quantidade e as condições de repetição serão definidas após o cenário piloto, considerando a variabilidade observada nas respostas.

3.3 ETAPAS DO TRABALHO

O desenvolvimento será dividido nas seguintes etapas:

1. definir uma base comum de informações e regras de atendimento;
2. especificar as arquiteturas de agente único e multiagente;
3. elaborar os prompts necessários para cada arquitetura;
4. implementar os dois protótipos e o registro das execuções;
5. elaborar e revisar os cenários conversacionais de teste;
6. realizar um experimento piloto para verificar o funcionamento dos protótipos e das métricas;
7. executar o conjunto de testes definido após o piloto;
8. consolidar e comparar os resultados obtidos.

3.4 MATERIAIS E FERRAMENTAS

Os protótipos serão desenvolvidos em Python. Os cenários de teste e os resultados das execuções serão armazenados em arquivos estruturados no formato JSON. O código-fonte, os prompts e os documentos auxiliares serão versionados com Git.

A avaliação automatizada será implementada inicialmente com a biblioteca DeepEval. O acesso ao modelo de linguagem será realizado por meio de API. O modelo, o provedor, os parâmetros de geração e as versões das ferramentas serão definidos e registrados antes da execução do experimento. Planilhas ou scripts em Python poderão ser utilizados para consolidar as medições e produzir as tabelas e os gráficos da análise.

O ambiente Orbsofty poderá ser utilizado para inspeção visual e comparação com um fluxo de atendimento em uso. Entretanto, as medições principais serão realizadas nos

protótipos controlados, evitando que regras operacionais externas interfiram na comparação entre as arquiteturas.

3.5 CENÁRIOS CONVERSACIONAIS

Os testes serão formados por conversas com múltiplos turnos, nas quais as informações serão apresentadas gradualmente. Cada cenário conterá as mensagens do usuário, o assunto esperado em cada etapa, o encaminhamento esperado na arquitetura multiagente, as informações que deverão permanecer no contexto e os critérios necessários para considerar a tarefa concluída.

O cenário piloto começará com uma solicitação comercial e, durante a mesma conversa, passará a tratar de uma falha de conexão. Esse caso permitirá observar se o sistema mantém as informações anteriores, identifica a mudança de assunto e, quando aplicável, transfere o atendimento ao agente adequado. Após o piloto, serão elaborados cenários adicionais para as áreas definidas no escopo do trabalho.

3.6 PROCEDIMENTO EXPERIMENTAL

Cada cenário será executado separadamente nas duas arquiteturas. As mensagens do usuário serão enviadas na ordem prevista no arquivo de teste, e a resposta produzida em cada turno será armazenada antes do envio da mensagem seguinte. Também serão registrados o agente responsável, as decisões de encaminhamento, o tempo de resposta, o consumo de tokens e o número de chamadas ao modelo.

As saídas serão avaliadas em relação aos critérios definidos para o cenário. A execução piloto será utilizada para verificar se os registros produzidos são suficientes, se as métricas escolhidas são aplicáveis e se há necessidade de repetir cada cenário. Alterações realizadas após o piloto serão documentadas antes da execução do conjunto definitivo de testes.

3.7 MÉTRICAS E CRITÉRIOS DE AVALIAÇÃO

A comparação considerará métricas relacionadas à qualidade da resposta, ao comportamento da conversa e ao consumo de recursos. Inicialmente, serão observados:

- correção e relevância das respostas;
- retenção das informações fornecidas nos turnos anteriores;
- conclusão da tarefa prevista no cenário;
- correspondência entre o encaminhamento realizado e o encaminhamento esperado;

- quantidade de transferências entre agentes;
- tempo de resposta por turno e tempo total da conversa;
- número de chamadas ao modelo e consumo de tokens.

As métricas baseadas em avaliação por modelo serão complementadas por verificações determinísticas sempre que houver um resultado objetivo, como o agente de destino, a presença de uma informação obrigatória ou a ocorrência de uma transferência. Os limites numéricos e critérios de sucesso serão definidos após a execução piloto, evitando a adoção de valores sem evidência experimental.

3.8 PRIVACIDADE E PROTEÇÃO DOS DADOS

Os cenários conversacionais serão produzidos especificamente para o estudo, com base em situações típicas de atendimento de provedores de Internet. Não serão utilizadas conversas, cadastros ou registros de clientes reais.

Os nomes, documentos, endereços, números de telefone, protocolos e demais informações presentes nos testes serão fictícios. A experiência profissional do autor será utilizada somente como referência para a elaboração das situações de atendimento, sem reprodução de casos que permitam identificar clientes, funcionários ou empresas. Dessa forma, não serão enviados dados pessoais reais aos modelos de linguagem ou às ferramentas utilizadas nos experimentos.

3.9 RISCOS E LIMITAÇÕES

Entre os riscos previstos estão a variação das respostas do modelo, alterações ou indisponibilidade da API, custo de execução, diferença excessiva entre os prompts e limitações da avaliação automática de respostas abertas. Também existe o risco de uma métrica baseada em modelo atribuir uma pontuação inadequada mesmo quando o comportamento esperado puder ser verificado objetivamente.

Como medidas de controle, todas as execuções serão registradas, as versões utilizadas serão identificadas e os encaminhamentos serão avaliados por regras determinísticas. Uma amostra das respostas poderá ser revisada manualmente. Caso o DeepEval não represente adequadamente alguma dimensão do experimento, a métrica correspondente será substituída ou complementada por um procedimento documentado. Também será realizada uma revisão dos cenários para impedir a inclusão acidental de dados associados a atendimentos reais.

REFERÊNCIAS

AMRI, M. F. et al. Optimizing LLM Chatbot to Human Handover with Multi-Agent AI Approach. In: 2026 International Conference on Advancement in Data Science, E-learning and Information System (ICADEIS). Jun. 2026. P. 1–6. DOI: 10.1109/ICADEIS71120.2026.11644567.

LEE, K.-Y.; TSENG, P.-A.; CHEN, W.-C. Enhancing Telecom Operation Support Systems with Multi-Agent Large Language Models. In: 2025 11th International Conference on Computing and Artificial Intelligence (ICCAI). Mar. 2025. P. 309–316. DOI: 10.1109/ICCAI66501.2025.00055.

MONCADA, C. et al. Large Language Models and Multi-Agent Systems for Customer Support Ticket Automation. In: 2025 IEEE Ninth Ecuador Technical Chapters Meeting (ETCM). Out. 2025. P. 1–6. DOI: 10.1109/ETCM67548.2025.11304425.

OWOTOGBE, Joshua. Assessing and Enhancing the Robustness of LLM-Based Multi-Agent Systems Through Chaos Engineering. In: 2025 IEEE/ACM 4th International Conference on AI Engineering – Software Engineering for AI (CAIN). Abr. 2025. P. 250–252. DOI: 10.1109/CAIN66642.2025.00039.

YAN, Bingyu et al. Beyond Self-Talk: A Communication-Centric Survey of LLM-Based Multi-Agent Systems. **Frontiers of Computer Science**, 2026. DOI: 10.1007/s11704-026-50857-y. Disponível em: <https://arxiv.org/abs/2502.14321>. Acesso em: 25 set. 2026.

YANG, Wangying; XU, Peng; ZHANG, Xiaogong. A Two-Stage Intent Recognition Framework in Multi-Agent Environments. In: 2025 6th International Conference on Computer Engineering and Application (ICCEA). Abr. 2025. P. 1–5. DOI: 10.1109/ICCEA65460.2025.11103313.