

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
DE SANTA CATARINA
CÂMPUS SÃO JOSÉ

WAGNER FLORES DOS SANTOS

**ANÁLISE COMPARATIVA ENTRE ARQUITETURAS DE AGENTE
ÚNICO E MULTIAGENTE BASEADAS EM LLM PARA
CHATBOTS DE ATENDIMENTO**

SÃO JOSÉ

2026

Wagner Flores dos Santos

Análise Comparativa entre Arquiteturas de Agente Único e Multiagente
Baseadas em LLM para Chatbots de Atendimento

Pré-projeto apresentado à Unidade Curricular de Trabalho de Conclusão de Curso I do Curso de Engenharia de Telecomunicações do Instituto Federal de Educação, Ciência e Tecnologia de Santa Catarina – Câmpus São José.

Área de concentração: Telecomunicações.

Orientador: Prof. Arliones Stevert Hoeller Júnior, Dr.

São José

2026

Wagner Flores dos Santos

Análise Comparativa entre Arquiteturas de Agente Único e Multiagente
Baseadas em LLM para Chatbots de Atendimento

Monografia apresentada ao Curso de Engenharia de Telecomunicações do Instituto Federal de Santa Catarina, para a obtenção do título de bacharel em Engenharia de Telecomunicações.

São José, 16 de abril de 2025.

Prof. Arliones Stevert Hoeller Júnior, Dr.
Instituto Federal de Santa Catarina

Professor Fulano, Dr.
Instituto Federal de Santa Catarina

Professora Fulana, Dra.
Instituto Federal de Santa Catarina

À minha família, pelo apoio, pela compreensão e por estar sempre ao meu lado durante esta caminhada.

AGRADECIMENTOS

Agradeço à minha família pelo apoio, pela compreensão e pelo incentivo durante toda a minha trajetória acadêmica. A presença de vocês foi fundamental para que eu pudesse enfrentar os desafios desta caminhada e seguir em frente nos momentos mais difíceis.

Ao meu orientador, Prof. Dr. Arliones Stevert Hoeller Júnior, agradeço pela disponibilidade, pelas orientações e pelas contribuições para o desenvolvimento deste trabalho.

Agradeço também ao Instituto Federal de Santa Catarina e aos professores do Curso de Engenharia de Telecomunicações, que contribuíram para a minha formação acadêmica e profissional.

Por fim, agradeço aos colegas com quem compartilhei experiências, dificuldades e aprendizados ao longo do curso.

“Penso, logo existo.” (René Descartes, 1637)

RESUMO

Os modelos de linguagem de grande escala (LLMs) ampliaram as possibilidades de automação do atendimento ao cliente, permitindo interpretar solicitações, consultar informações e produzir respostas mais flexíveis do que as obtidas com fluxos baseados apenas em regras. Ainda não está claro, porém, em quais condições a distribuição das responsabilidades entre agentes especializados oferece vantagens suficientes para compensar o aumento da complexidade e do consumo de recursos em relação a uma arquitetura de agente único. Este trabalho tem como objetivo comparar experimentalmente as duas arquiteturas em um cenário controlado de atendimento textual de um provedor de Internet, considerando a correção e a relevância das respostas, a conclusão das tarefas, a precisão dos encaminhamentos, o tempo de resposta e o consumo de tokens. Para isso, serão implementados dois protótipos, submetidos ao mesmo conjunto balanceado de casos de teste e às mesmas condições de execução, com avaliação apoiada pelo DeepEval e por métricas registradas diretamente durante o experimento. Espera-se identificar em quais situações a especialização por agentes setoriais melhora o atendimento e quais efeitos essa organização produz sobre a latência, o uso de tokens e o custo operacional.

Palavras-chave: modelos de linguagem de grande escala; sistemas multiagentes; chatbots; atendimento ao cliente; agentes inteligentes.

ABSTRACT

This is the english abstract.

Keywords: latex; abntex; text editoration.

LISTA DE ILUSTRAÇÕES

LISTA DE QUADROS

Quadro 1 – Síntese dos trabalhos relacionados	23
---	----

LISTA DE TABELAS

LISTA DE CÓDIGOS

Código 3.1 – Olá mundo em shell script	25
Código 3.2 – Um pequeno código em MatLab	25
Código 3.3 – Aluno representado em JSON	25

LISTA DE ABREVIATURAS E SIGLAS

ABNT Associação Brasileira de Normas Técnicas.

AbnTeX ABsurdas Normas para TeX.

AC Autoridade Certificadora.

LLM modelo de linguagem de grande escala (*Large Language Model*).

TLS *Transport Layer Security*.

LISTA DE SÍMBOLOS

$\emptyset$ conjunto vazio.

π número Pi.

SUMÁRIO

1	INTRODUÇÃO	15
1.1	PROBLEMA DE PESQUISA	16
1.2	JUSTIFICATIVA	16
1.3	OBJETIVOS	17
1.3.1	Objetivo geral	17
1.3.2	Objetivos específicos	17
1.4	DELIMITAÇÃO DO TRABALHO	18
2	REVISÃO BIBLIOGRÁFICA	19
2.1	FUNDAMENTAÇÃO TEÓRICA	19
2.1.1	Modelos de linguagem de grande escala	19
2.1.2	Agentes baseados em modelos de linguagem	19
2.1.3	Arquiteturas de agente único e multiagente	20
2.1.4	Comunicação, orquestração e retenção de contexto	21
2.1.5	Avaliação de sistemas conversacionais	21
2.2	TRABALHOS RELACIONADOS	22
2.3	SÍNTESE DA REVISÃO E LACUNA DE PESQUISA	24
3	PROPOSTA	25
3.1	INCLUINDO TRECHOS DE CÓDIGOS	25
3.2	COMO APRESENTAR EQUAÇÕES	26
3.3	USANDO SIGLAS, ABREVIATURAS E SÍMBOLOS	26
3.4	REFERÊNCIAS BIBLIOGRÁFICAS	27
3.5	CITAÇÕES DIRETAS	27
4	CONCLUSÕES	29
	Referências	30
	APÊNDICE A – MEU PRIMEIRO APÊNDICE	32
	ANEXO A – MEU PRIMEIRO ASSUNTO DE ANEXO	33
	ANEXO B – SEGUNDO ASSUNTO QUE PESQUISEI	34

1 INTRODUÇÃO

Os modelos de linguagem de grande escala (LLMs, *Large Language Model*) ampliaram as possibilidades de automação de atividades que envolvem compreensão e geração de linguagem natural. Quando integrados a bases de informações, ferramentas e mecanismos de decisão, esses modelos podem formar agentes capazes de interpretar solicitações, manter o contexto de uma conversa e executar tarefas com algum grau de autonomia. No atendimento ao cliente, essa abordagem permite desenvolver soluções mais flexíveis do que os chatbots baseados apenas em regras e fluxos predefinidos.

Trabalhos recentes apresentam aplicações de LLMs na classificação de chamados e na geração de respostas de suporte (MONCADA et al., 2025), bem como arquiteturas formadas por agentes coordenadores e especializados para atuar em diferentes componentes de sistemas de telecomunicações (LEE; TSENG; CHEN, 2025). Essas soluções podem ser organizadas em arquiteturas de agente único ou multiagente.

Na arquitetura de agente único, um mesmo componente recebe as mensagens, mantém o histórico da conversa, consulta as informações disponíveis, decide o procedimento e produz as respostas. Essa centralização reduz a necessidade de coordenação entre componentes. Em uma arquitetura multiagente, essas responsabilidades são distribuídas entre agentes com funções específicas, como triagem, atendimento comercial, primeiro atendimento, ouvidoria e suporte técnico. A divisão pode facilitar a especialização e reduzir o contexto recebido por cada agente, mas também introduz etapas adicionais de comunicação e novos pontos de falha (YAN et al., 2026).

A comunicação entre os agentes influencia a eficiência, a escalabilidade e a robustez do sistema. Uma decisão incorreta na triagem pode encaminhar a conversa para um agente que não possui as informações necessárias. Também podem ocorrer perdas de contexto, encaminhamentos desnecessários ou propagação de erros entre os componentes. Esses riscos tornam relevante avaliar não apenas a resposta final, mas também o caminho percorrido pelo atendimento (OWOTOGBE, 2025).

A literatura também apresenta estudos sobre o encaminhamento de conversas para atendimento humano e o reconhecimento de intenções em ambientes multiagentes (AMRI et al., 2026; YANG; XU; ZHANG, 2025). Os resultados apontam benefícios da especialização, mas também mostram que a vantagem da arquitetura multiagente não ocorre em todas as métricas e pode vir acompanhada de maior latência ou de transferências realizadas mais cedo. Além disso, os trabalhos adotam diferentes modelos, cenários e critérios de avaliação, o que dificulta uma comparação direta entre arquiteturas de agente único e multiagente.

Esses resultados indicam que a adoção de uma arquitetura multiagente não representa, necessariamente, uma melhoria em todas as situações. Ainda são necessárias comparações nas quais as arquiteturas utilizem o mesmo modelo, a mesma base de informações, parâmetros equivalentes e cenários de atendimento comparáveis. Também é necessário observar o comportamento ao longo da conversa, considerando a retenção do contexto, as decisões de encaminhamento e os recursos utilizados até a conclusão da tarefa.

1.1 PROBLEMA DE PESQUISA

A escolha entre uma arquitetura de agente único e uma arquitetura multiagente envolve um compromisso entre qualidade, complexidade e custo operacional. A especialização pode melhorar o tratamento de determinadas solicitações, mas exige coordenação entre agentes e pode aumentar o número de chamadas ao modelo, a latência e o consumo de tokens.

Além disso, uma avaliação baseada somente em perguntas isoladas não representa todo o funcionamento de um chatbot de atendimento. Em uma conversa real, as informações são fornecidas gradualmente, e uma resposta depende das mensagens anteriores. O sistema também pode precisar rever o encaminhamento quando o usuário apresenta uma nova informação ou muda o assunto durante o atendimento.

Diante desse contexto, este trabalho busca responder à seguinte pergunta:

Quais diferenças de desempenho são observadas entre uma arquitetura de agente único e uma arquitetura multiagente, ambas baseadas em modelos de linguagem de grande escala e aplicadas a cenários conversacionais de atendimento, quanto à correção e à relevância das respostas, à retenção do contexto, à conclusão das tarefas, à precisão dos encaminhamentos, ao tempo de resposta e ao consumo de tokens?

1.2 JUSTIFICATIVA

A escolha da arquitetura influencia tanto a qualidade do atendimento quanto o custo de operação de sistemas baseados em LLMs. Uma solução centralizada pode ser suficiente para tarefas simples e utilizar menos chamadas ao modelo. Por outro lado, a distribuição das responsabilidades entre agentes especializados pode favorecer situações que exigem regras específicas ou mudanças de setor durante uma conversa, embora acrescente etapas de comunicação e novos pontos de falha (YAN et al., 2026).

No atendimento de provedores de Internet, uma mesma conversa pode envolver dúvidas gerais, solicitações comerciais, reclamações e problemas técnicos. Um encaminha-

mento incorreto pode levar o usuário para uma fila inadequada, prolongar o atendimento ou produzir uma resposta sem as informações necessárias. Estudos anteriores demonstram que a especialização pode melhorar determinadas métricas, mas essa vantagem não ocorre em todas as situações. Também foi observada uma tendência de o sistema multiagente realizar transferências para o atendimento humano mais cedo (AMRI et al., 2026).

A contribuição esperada deste trabalho é a implementação de dois protótipos equivalentes e a realização de uma comparação controlada entre as arquiteturas. A avaliação considerará tanto o resultado final quanto a trajetória da conversa, incluindo a retenção do contexto, os encaminhamentos realizados, a quantidade de turnos e os recursos consumidos. Os resultados poderão servir como referência para pesquisadores e desenvolvedores na escolha de uma arquitetura compatível com os requisitos de qualidade, desempenho e custo da aplicação.

1.3 OBJETIVOS

1.3.1 Objetivo geral

Comparar experimentalmente o desempenho de uma arquitetura de agente único e de uma arquitetura multiagente, ambas baseadas em modelos de linguagem de grande escala e aplicadas a cenários conversacionais de atendimento textual de um provedor de internet.

1.3.2 Objetivos específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- definir uma base comum de informações e regras de atendimento para as duas arquiteturas;
- implementar um protótipo de agente único e um protótipo multiagente composto por um agente de triagem e agentes especializados;
- elaborar e validar um conjunto de cenários conversacionais de teste para primeiro atendimento, comercial, ouvidoria e suporte técnico;
- avaliar a correção e a relevância das respostas, a retenção do contexto, a conclusão das tarefas e a precisão dos encaminhamentos;
- medir o tempo de resposta, o consumo de tokens, o número de chamadas ao modelo, a quantidade de turnos e as trocas de agente realizadas durante cada conversa;
- comparar os resultados para identificar as vantagens, limitações e custos de cada arquitetura.

1.4 DELIMITAÇÃO DO TRABALHO

O estudo será restrito ao atendimento textual e utilizará cenários sintéticos baseados em situações de um provedor de Internet. Os dados empregados serão fictícios ou anonimizados, sem interação com clientes reais.

As duas arquiteturas utilizarão o mesmo modelo de linguagem, os mesmos parâmetros de geração e a mesma base geral de informações. No agente único, todas as regras serão reunidas em um único contexto. No sistema multiagente, o conteúdo será distribuído conforme as responsabilidades de cada agente.

Não fazem parte do escopo o atendimento por voz, o processamento de conteúdo multimodal, o treinamento ou ajuste fino de modelos, a comparação entre diferentes LLMs e a implantação do sistema com clientes reais. Também não serão realizados testes de robustez com injeção deliberada de falhas nos agentes ou na comunicação.

2 REVISÃO BIBLIOGRÁFICA

Este capítulo apresenta os conceitos utilizados no desenvolvimento do trabalho e discute pesquisas relacionadas ao uso de modelos de linguagem em sistemas de atendimento. São abordados os agentes baseados em modelos de linguagem, as arquiteturas de agente único e multiagente, a comunicação entre agentes e os critérios empregados na avaliação de sistemas conversacionais.

2.1 FUNDAMENTAÇÃO TEÓRICA

2.1.1 Modelos de linguagem de grande escala

Os modelos de linguagem de grande escala são capazes de interpretar instruções e produzir textos a partir do contexto fornecido em sua entrada. Em sistemas de atendimento, esses modelos podem ser utilizados para identificar a intenção do usuário, consultar informações e elaborar respostas adequadas à solicitação recebida.

Diferentemente de um fluxo baseado somente em regras fixas, um sistema apoiado em LLMs pode tratar diferentes formas de expressar uma mesma intenção. Essa característica é útil em conversas nas quais o usuário não segue um roteiro predefinido ou fornece as informações de maneira incompleta.

O comportamento do modelo depende das instruções, das informações disponíveis e do histórico incluído no contexto. Uma resposta também pode variar entre execuções, mesmo quando a entrada é semelhante. Por esse motivo, a utilização de LLMs em processos de atendimento exige critérios que permitam verificar a correção das respostas e o cumprimento das regras definidas para o serviço.

Yang, Xu e Zhang observam que modelos de linguagem podem melhorar o reconhecimento de intenções em comparação com métodos baseados somente em regras ou classificação tradicional. Os autores também destacam o custo computacional e a latência associados ao seu uso (YANG; XU; ZHANG, 2025). Esses fatores são relevantes neste trabalho porque as arquiteturas comparadas podem realizar quantidades diferentes de chamadas ao modelo.

2.1.2 Agentes baseados em modelos de linguagem

Um agente baseado em modelo de linguagem combina o modelo com instruções que definem sua função, informações de contexto e mecanismos para executar ações. Em um chatbot de atendimento, essas ações podem incluir classificar uma solicitação, consultar uma base de informações, formular uma resposta ou encaminhar a conversa para outro

setor.

As instruções fornecidas ao agente delimitam sua atuação. Um agente de suporte técnico, por exemplo, pode receber regras sobre os testes permitidos, os dados que devem ser solicitados e as situações que exigem transferência para atendimento humano. O histórico da conversa permite utilizar informações fornecidas em mensagens anteriores e evitar que o usuário tenha que repeti-las.

Moncada et al. utilizam agentes especializados para realizar a ingestão de dados, a classificação de chamados e a geração de respostas em uma aplicação de suporte ao cliente (MONCADA et al., 2025). O trabalho mostra que uma tarefa de atendimento pode ser dividida entre componentes com responsabilidades distintas. Essa divisão, entretanto, exige que as informações necessárias sejam transmitidas corretamente entre os agentes.

2.1.3 Arquiteturas de agente único e multiagente

Na arquitetura de agente único, um mesmo agente concentra as funções necessárias ao atendimento. Ele recebe as mensagens, interpreta a solicitação, mantém o histórico, consulta as informações disponíveis e produz a resposta. As regras dos diferentes setores ficam reunidas no contexto desse agente.

Essa organização reduz a necessidade de encaminhamentos internos. Por outro lado, o aumento da quantidade de regras e assuntos pode tornar o contexto mais extenso e dificultar a separação das responsabilidades. O agente precisa identificar quais instruções devem ser aplicadas em cada situação.

Na arquitetura multiagente, as responsabilidades são divididas entre agentes com funções específicas. Um agente pode realizar a triagem da conversa, enquanto outros tratam de assuntos comerciais, técnicos ou administrativos. Lee, Tseng e Chen apresentam uma organização semelhante para sistemas de suporte à operação de telecomunicações, composta por um agente principal e agentes especializados (LEE; TSENG; CHEN, 2025).

A especialização permite limitar as instruções e informações recebidas por cada agente. Em contrapartida, torna necessário definir como o sistema seleciona o próximo agente e quais partes do histórico serão transferidas. Assim, parte do desempenho da arquitetura passa a depender do mecanismo de coordenação.

Amri et al. comparam arquiteturas de agente único e multiagente no encaminhamento de conversas para atendimento humano (AMRI et al., 2026). Os resultados apresentados pelos autores indicam diferenças entre as arquiteturas, mas não demonstram vantagem da abordagem multiagente em todos os critérios. Essa constatação reforça a necessidade de comparar as duas alternativas sob as mesmas condições.

2.1.4 Comunicação, orquestração e retenção de contexto

A orquestração corresponde ao controle do fluxo de execução entre os agentes. Em uma arquitetura multiagente de atendimento, esse mecanismo recebe a mensagem, identifica a função necessária e direciona a conversa para o agente responsável. Quando o assunto muda, uma nova decisão de encaminhamento pode ser necessária.

Yan et al. analisam os sistemas multiagentes a partir da comunicação estabelecida entre seus componentes (YAN et al., 2026). Segundo essa perspectiva, não basta avaliar separadamente a capacidade de cada agente, pois o resultado também depende das mensagens trocadas e das decisões tomadas durante a execução.

Em uma conversa com vários turnos, as informações costumam ser fornecidas aos poucos. O usuário pode informar inicialmente que está sem acesso à Internet e, somente depois, relatar o estado das luzes do equipamento. Se houver troca de agente entre essas mensagens, o novo agente precisa receber os dados já coletados.

Neste trabalho, a retenção de contexto será observada pela capacidade de utilizar corretamente informações apresentadas em mensagens anteriores. Também serão registrados os encaminhamentos realizados ao longo da conversa. Com isso, será possível distinguir um erro na resposta de um erro ocorrido anteriormente na triagem ou na transferência de informações.

Falhas em um componente podem afetar as etapas seguintes de um sistema multiagente. Owotogbe discute esse problema ao investigar a robustez de sistemas formados por agentes baseados em modelos de linguagem (OWOTOGBE, 2025). Embora a injeção deliberada de falhas não faça parte do escopo deste trabalho, a possibilidade de propagação de erros justifica o acompanhamento do fluxo percorrido por cada atendimento.

2.1.5 Avaliação de sistemas conversacionais

A avaliação de um sistema conversacional pode considerar tanto a resposta entregue ao usuário quanto o processo utilizado para produzi-la. Uma resposta pode estar correta, mas ter sido obtida após encaminhamentos desnecessários, repetição de perguntas ou uso excessivo de chamadas ao modelo.

A correção indica se a resposta está de acordo com as informações disponíveis. A relevância verifica se ela trata diretamente da solicitação apresentada. A retenção de contexto observa se os dados fornecidos anteriormente foram utilizados de forma adequada. Já a conclusão da tarefa verifica se o objetivo definido para o cenário foi alcançado.

Em uma arquitetura multiagente, também é necessário avaliar a precisão dos encaminhamentos. Essa medida permite verificar se cada mensagem foi direcionada ao agente responsável pelo assunto. As métricas de qualidade podem ser acompanhadas por medidas operacionais, como tempo de resposta, consumo de tokens, número de chamadas ao

modelo e quantidade de trocas de agente.

Esses critérios permitem comparar as arquiteturas para além da resposta final. No experimento proposto, os mesmos cenários, o mesmo modelo de linguagem e a mesma base de informações serão empregados nos dois protótipos. Os detalhes das métricas e do procedimento experimental serão apresentados no capítulo de metodologia.

2.2 TRABALHOS RELACIONADOS

Os trabalhos analisados abordam diferentes aspectos do uso de modelos de linguagem e sistemas multiagentes. Alguns apresentam aplicações voltadas ao atendimento, enquanto outros tratam do reconhecimento de intenções, da comunicação entre agentes e da robustez dessas arquiteturas.

Moncada et al. (2025) apresentam uma arquitetura multiagente para automação de chamados de suporte. A solução foi implementada com o *framework* CrewAI e distribui as tarefas entre agentes responsáveis pela entrada dos dados, classificação dos chamados e geração das respostas. Os autores relatam resultados de acurácia na classificação e de similaridade semântica entre as respostas produzidas e as respostas esperadas. O trabalho demonstra uma aplicação prática da especialização de agentes, mas não realiza uma comparação controlada com uma arquitetura de agente único nem acompanha conversas com múltiplos turnos.

No contexto das telecomunicações, Lee, Tseng e Chen (2025) propõem uma arquitetura para sistemas de suporte à operação. A organização é composta por um agente principal, responsável pela coordenação, e agentes específicos, encarregados de tarefas relacionadas a diferentes áreas do sistema. Os autores apontam benefícios relacionados à flexibilidade e à divisão de responsabilidades. Entretanto, o estudo concentra-se na descrição da arquitetura e não apresenta uma comparação experimental entre agente único e multiagente utilizando os mesmos cenários e parâmetros.

O reconhecimento de intenções é investigado por Yang, Xu e Zhang (2025). Os autores propõem uma abordagem em duas etapas: inicialmente, é realizada uma tentativa de classificação utilizando TF-IDF; quando essa etapa não é suficiente, um modelo de linguagem é empregado. A proposta procura equilibrar precisão, latência e custo computacional. O estudo é pertinente ao mecanismo de triagem, mas sua avaliação está concentrada na identificação da intenção, sem abranger a continuidade do atendimento depois do encaminhamento.

Amri et al. (2026) comparam arquiteturas de agente único e multiagente na decisão de encaminhar uma conversa para atendimento humano. Para realizar os testes, os autores utilizam uma base formada por diálogos de atendimento e comparam o desempenho das arquiteturas com diferentes modelos de linguagem. Os resultados indicam

melhor desempenho do sistema multiagente em parte das medidas avaliadas. Entretanto, também mostram que a organização em múltiplos agentes pode alterar o momento em que ocorre a transferência. O estudo é próximo da proposta deste trabalho, mas está concentrado na decisão de transferência para humanos.

A comunicação em sistemas multiagentes baseados em modelos de linguagem é analisada por Yan et al. (2026). Os autores organizam as arquiteturas a partir dos participantes, dos tipos de mensagens, das estruturas de comunicação e das estratégias utilizadas para coordenar as tarefas. A revisão também discute problemas como aumento do custo de comunicação, propagação de erros e dificuldade de manter informações consistentes entre os agentes. Por se tratar de uma revisão, o trabalho não realiza uma comparação experimental própria, mas fornece a base conceitual para analisar a comunicação entre os componentes.

A robustez dos sistemas multiagentes é discutida por Owotogbe (2025), que propõe o uso de princípios de engenharia do caos para avaliar o comportamento do sistema diante de falhas. O trabalho considera que problemas em um agente ou na comunicação podem afetar o resultado produzido pelos demais componentes. Embora este TCC não inclua a injeção deliberada de falhas, essa discussão mostra a importância de registrar os encaminhamentos e observar em qual etapa ocorre um resultado incorreto.

O Quadro 1 resume as principais características dos trabalhos analisados e sua relação com a proposta desta pesquisa.

Quadro 1 – Síntese dos trabalhos relacionados

Trabalho	Aplicação	Abordagem	Limitação em relação a este TCC
Moncada et al. (MONCADA et al., 2025)	Chamados de suporte	Agentes para entrada dos dados, classificação e geração de respostas	Não compara as duas arquiteturas nem avalia conversas com múltiplos turnos
Lee, Tseng e Chen (LEE; TSENG; CHEN, 2025)	Operações de telecomunicações	Agente principal coordenando agentes especializados	Não apresenta comparação experimental controlada entre agente único e multiagente
Yang, Xu e Zhang (YANG; XU; ZHANG, 2025)	Reconhecimento de intenção	Classificação inicial com TF-IDF e uso de LLM como segunda etapa	Avalia a identificação da intenção, mas não a continuidade do atendimento
Amri et al. (AMRI et al., 2026)	Transferência para atendimento humano	Comparação entre agente único e multiagente	Concentra-se na decisão de transferência para atendimento humano
Yan et al. (YAN et al., 2026)	Comunicação entre agentes	Revisão de arquiteturas, mensagens e estratégias de comunicação	Não realiza comparação experimental própria
Owotogbe (OWOTOGBE, 2025)	Robustez de sistemas multiagentes	Aplicação de princípios de engenharia do caos	Possui procedimento e objetivo experimental diferentes

Fonte: Elaborada pelo autor.

2.3 SÍNTESE DA REVISÃO E LACUNA DE PESQUISA

Os trabalhos analisados mostram que a divisão de responsabilidades entre agentes pode ser aplicada à classificação de solicitações, ao encaminhamento de conversas e à execução de tarefas especializadas. Também indicam que a comunicação entre os componentes pode aumentar a complexidade do sistema e introduzir problemas relacionados à latência, ao consumo de recursos e à perda de informações.

Entre os estudos selecionados, o trabalho de Amri et al. (2026) é o que mais se aproxima da comparação proposta neste TCC. Entretanto, sua avaliação está direcionada ao encaminhamento para atendimento humano. Os demais estudos analisam aplicações ou aspectos específicos das arquiteturas, sem comparar agente único e multiagente durante conversas que possam envolver diferentes setores.

Permanece, portanto, a necessidade de uma comparação na qual as duas arquiteturas utilizem o mesmo modelo de linguagem, a mesma base de informações, parâmetros equivalentes e os mesmos cenários de atendimento. Além da resposta final, essa comparação deve observar a retenção das informações fornecidas ao longo da conversa, as decisões de encaminhamento e os recursos utilizados por cada arquitetura.

Com base nessa lacuna, este trabalho propõe implementar dois protótipos equivalentes e submetê-los a cenários conversacionais de atendimento de um provedor de Internet. O procedimento de implementação, os cenários e as métricas de avaliação são apresentados no capítulo seguinte.

3 PROPOSTA

3.1 INCLUINDO TRECHOS DE CÓDIGOS

Em alguns casos é desejado incluir trechos de códigos no documento. O $\text{\LaTeX}$ oferece inúmeras maneiras para isto e o pacote **listings** é conhecido por apresentar um dos melhores resultados. A Código 3.1 apresenta o código em *shell script* para o complexo problema do “Olá mundo!”. A Código 3.2 apresenta um trecho de código em MatLab e por fim, na Código 3.3 é ilustrado um aluno representado em um documento JSON.

Código 3.1 – Olá mundo em shell script

```
1 #!/bin/bash
2
3 echo "Ola mundo!"
```

Código 3.2 – Um pequeno código em MatLab

```
1 fs = 10000;
2 t = 0:1/fs:1.5;
3 x1 = sawtooth(2*pi*50*t);
4 x2 = square(2*pi*50*t);
5 subplot(211),plot(t,x1), axis([0 0.2 -1.2 1.2])
6 xlabel('Time (sec)');
7 ylabel('Amplitude');
8 title('Sawtooth Periodic Wave');
9 subplot(212)
10 plot(t,x2)
11 axis([0 0.2 -1.2 1.2]);
12 xlabel('Time (sec)');
13 ylabel('Amplitude');
14 title('Square Periodic Wave');
```

Código 3.3 – Aluno representado em JSON

```
1 {
2     "nome" : "Juca Petro",
3     "cpf" : "123.456.789-00",
4     "idade" : 20,
5     "disciplinas" : [ "P00", "STD"]
6 }
```

3.2 COMO APRESENTAR EQUAÇÕES

O $\LaTeX$ é um pacote feito para a preparação de textos impressos de alta qualidade, especialmente para textos matemáticos. Ele foi desenvolvido por Leslie Lamport a partir do programa $\TeX$ criado por Donald Knuth.

Fórmulas matemáticas são produzidas diretamente no arquivo fonte texto. Isto significa que o $\LaTeX$ deve ser informado que o texto que vem a seguir é uma fórmula e também quando ela termina e o texto normal recomeça. As fórmulas podem ocorrer em uma linha de texto como $ax^2 + bx + c = 0$, ou destacada do texto principal como os exemplos apresentados na Equação 3.1 e Equação 3.2.

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \quad (3.1)$$

$$\begin{aligned} f(x) &= x^2 \\ g(x) &= \frac{1}{\sqrt{x}} \\ F(x) &= \int_b^a \frac{1}{3} x^3 \end{aligned} \quad (3.2)$$

3.3 USANDO SIGLAS, ABREVIATURAS E SÍMBOLOS

Algumas vezes nos deparamos com textos cheios de siglas ou símbolos. Existem diversos pacotes e formas para gerar glossário, lista de acrônimos, lista de símbolos etc. com $\LaTeX$. Neste parágrafo é feito uso de comandos definidos no pacote *glossaries-extra*¹. A listagem de acrônimos fica dentro do arquivo `pretextuais/abreviaco-es-siglas.tex` e a listagem de símbolos fica dentro do arquivo `pretextuais/simbolos.tex`.

O símbolo $\emptyset$ representa um conjunto vazio, já o símbolo π representa o número Pi. O protocolo *Transport Layer Security* (TLS) deve ser empregado sempre que se deseja garantir a integridade e a confidencialidade das mensagens trocadas pela rede. O TLS é hoje utilizado por diversas aplicações. Como faz tempo que eu não falo do *Transport Layer Security* (TLS) eu chamo o nome completo mais a sigla, ajudando o meu leitor a lembrar da sigla TLS. Existem as Autoridades Certificadoras (ACs) que são bem importante. Este documento segue as normas da Associação Brasileira de Normas Técnicas (ABNT) e para isso faz uso do pacote *ABsurdas Normas para TeX* (`abnTeX`).

Abaixo são apresentados os comandos providos pelo pacote *glossaries-extra*:

¹ <https://www.ctan.org/pkg/glossaries-extra>

- `\gls{rotulo}` – Na primeira vez que o acrônimo for chamado será impresso o valor por extenso e o acrônimo. Ex: `\gls{IFSC}` irá imprimir Instituto Federal de Santa Catarina (IFSC). Nas demais vezes irá imprimir somente o acrônimo;
- `\glspl{rotulo}` – Semelhante ao anterior, mas imprime a forma no plural;
- `\glstrshort{rotulo}` – Para imprimir somente o acrônimo;
- `\glstrlong{rotulo}` – Para imprimir somente o valor por extenso;
- `\glstrfull{rotulo}` – Para imprimir o valor por extenso e o acrônimo, mesmo que o acrônimo já tenha sido invocado previamente.

3.4 REFERÊNCIAS BIBLIOGRÁFICAS

A formatação das referências bibliográficas conforme as regras da ABNT são um dos principais objetivos do `abnTeX2`. Consulte os manuais Araujo (2015a) e Araujo (2015b) para obter informações sobre como utilizar as referências bibliográficas.

O uso de citações ao longo do texto é uma prática desejável. Por exemplo, em (LAMPORT et al., 1994) é apresentado um documento sobre a preparação de textos usando `LaTeX`. Já em (GOOSSENS; MITTELBACH; SAMARIN, 1994) é apresentada uma lista de referências rápidas para realizar as mais simples tarefas em `LaTeX`.

É o caso em que você menciona *explicitamente* o autor da referência na sentença, algo do tipo “Fulano (1900)”. Neste caso o nome do autor é escrito normalmente. Para isso use o comando `\textcite`.

A ironia será assim uma ... proposta por Lamport et al. (1994). Este documento segue as normas da ABNT e para isso faz uso do pacote `abnTeX`.

3.5 CITAÇÕES DIRETAS

Utilize o ambiente `citacao` para incluir citações diretas com mais de três linhas:

As citações diretas, no texto, com mais de três linhas, devem ser destacadas com recuo de 4 cm da margem esquerda, com letra menor que a do texto utilizado e sem aspas. No caso de documentos datilografados, deve-se observar apenas o recuo (ABNT, 2002, p. 5.3).

Use o ambiente assim:

```
\begin{citacao}
As citações diretas, no texto, com mais de três linhas [\ldots]
deve-se observar apenas o recuo \cite[5.3]{NBR10520:2002}.
\end{citacao}
```

O ambiente `citacao` pode receber como parâmetro opcional um nome de idioma previamente carregado nas opções da classe. Nesse caso, o texto da citação é automaticamente escrito em itálico e a hifenização é ajustada para o idioma selecionado na opção do ambiente. Por exemplo:

```
\begin{citacao}[english]
Text in English language in italic with correct hyphenation.
\end{citacao}
```

Tem como resultado:

Text in English language in italic with correct hyphenation.

Citações simples, com até três linhas, devem ser incluídas com aspas. Observe que em $\text{\LaTeX}$ as aspas iniciais são diferentes das finais: “Amor é fogo que arde sem se ver”.

4 CONCLUSÕES

Este trabalho procurou mostrar como deverá ser a apresentação da monografia a ser submetida à Coordenação do Curso de Engenharia de Telecomunicações do IFSC para a obtenção do diploma de Bacharel em Engenharia de Telecomunicações.

No Capítulo 1 foi feita uma pequena introdução. No Capítulo 2 foi apresentado o uso de alguns ambientes flutuantes no $\text{\LaTeX}$. E no Capítulo 3 foi apresentado sobre equações e como inserir trechos de código.

Como trabalho futuro, fica a reescrita do texto deste documento de forma que ele possam indicar informações específicas a formatação do documento. Como o tamanho da fonte utilizada, o espaçamento da borda, o alinhamento e numeração das seções e capítulos etc.

REFERÊNCIAS

- AMRI, M. F. et al. Optimizing LLM Chatbot to Human Handover with Multi-Agent AI Approach. In: 2026 International Conference on Advancement in Data Science, E-learning and Information System (ICADEIS). Jun. 2026. P. 1–6. DOI: 10.1109/ICADEIS71120.2026.11644567.
- ARAÚJO, Lauro César. **O pacote abntex2cite: Estilos bibliográficos compatíveis com a ABNT NBR 6023**. 2015. Disponível em: <<http://www.abntex.net.br/>>.
- _____. **O pacote abntex2cite: tópicos específicos da ABNT NBR 10520:2002 e o estilo bibliográfico alfabético (sistema autor-data)**. 2015. Disponível em: <<http://www.abntex.net.br/>>.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 10520**: Informação e documentação — Apresentação de citações em documentos. Rio de Janeiro, ago. 2002. P. 7.
- GOOSSENS, M.; MITTELBAACH, F.; SAMARIN, A. **The LATEX companion**. Addison-Wesley, 1994.
- LAMPORT, L. et al. **La T E X: A Document Preparation System**. Addison-Wesley, Reading, Massachusetts, 1994.
- LEE, K.-Y.; TSENG, P.-A.; CHEN, W.-C. Enhancing Telecom Operation Support Systems with Multi-Agent Large Language Models. In: 2025 11th International Conference on Computing and Artificial Intelligence (ICCAI). Mar. 2025. P. 309–316. DOI: 10.1109/ICCAI66501.2025.00055.
- MONCADA, C. et al. Large Language Models and Multi-Agent Systems for Customer Support Ticket Automation. In: 2025 IEEE Ninth Ecuador Technical Chapters Meeting (ETCM). Out. 2025. P. 1–6. DOI: 10.1109/ETCM67548.2025.11304425.
- OWOTOGBE, Joshua. Assessing and Enhancing the Robustness of LLM-Based Multi-Agent Systems Through Chaos Engineering. In: 2025 IEEE/ACM 4th International Conference on AI Engineering – Software Engineering for AI (CAIN). Abr. 2025. P. 250–252. DOI: 10.1109/CAIN66642.2025.00039.
- YAN, Bingyu et al. Beyond Self-Talk: A Communication-Centric Survey of LLM-Based Multi-Agent Systems. **Frontiers of Computer Science**, 2026. DOI: 10.1007/s11704-026-50857-y. Disponível em: <<https://arxiv.org/abs/2502.14321>>. Acesso em: 25 set. 2026.

YANG, Wangying; XU, Peng; ZHANG, Xiaogong. A Two-Stage Intent Recognition Framework in Multi-Agent Environments. In: 2025 6th International Conference on Computer Engineering and Application (ICCEA). Abr. 2025. P. 1–5. DOI: 10.1109/ICCEA65460.2025.11103313.

APÊNDICE A – MEU PRIMEIRO APÊNDICE

Texto ou documento, elaborado pelo autor, a fim de complementar sua argumentação, sem prejuízo da unidade nuclear do trabalho. Os apêndices são identificados por letras maiúsculas ordenadas alfabeticamente, travessão e pelo respectivo título.

ANEXO A – MEU PRIMEIRO ASSUNTO DE ANEXO

Texto ou documento não elaborado pelo autor, que serve de fundamentação, comprovação e ilustração. Os anexos são identificados por letras maiúsculas ordenadas alfabeticamente, travessões e pelos respectivos títulos.

ANEXO B – SEGUNDO ASSUNTO QUE PESQUISEI

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.